Azərbaycan Dili üçün Nitq Tanıma (ASR) Sistemi
Hesabat

AI Engineer Intern

May 4, 2026

Giriş

Bu hesabat Azərbaycan dili üçün avtomatik nitq tanıma (ASR) sisteminin qurulması, test edilməsi və optimallaşdırılması prosesini əhatə edir. Tapşırıq çərçivəsində "OpenAI Whisper" modeli üzərində testlər aparılmış, daha sonra isə LoRA (Low-Rank Adaptation) istifadə edilərək "fine-tuning" edilmişdir.

1 Hissə A: ASR Baza Tətbiqi

İlkin mərhələdə `openai/whisper-small` modeli "zero-shot" (əlavə təlim olmadan) rejimində test edilmişdir. Test üçün 126 audio səs faylı istifadə edilmiş, Ortalama Word Error Rate (WER) 92.77%, Character Error Rate (CER) isə 42.51% olaraq ölçülmüşdür.

Bu test zamanı bəzi problemlər müşahidə edilmişdir. Xüsusilə, ən pis proqnozlar (worst predictions) analiz edildikdə, modelin bəzi audio fayllarını ərəb/fars əlifbası ilə transkripsiya etdiyini görmək mümkündür. Bu cür hallüsinasiyalar bəzi cümlələr üçün WER göstəricisinin 22.2 kimi çox yüksək rəqəmə çatmasına səbəb olmuşdur.

2 Hissə B: Fine-Tuning

Bu hissədə baza modelindəki çatışmazlıqları aradan qaldırmaq üçün model azərbaycan dili üzrə "fine-tune" edilmişdir.

Training üçün 200, validation (dev) üçün 50 nümunə istifadə edilmişdir. Nəzərə alsaq ki training üçün sadəcə 200 audio fayl istifadə edilir, baza modelini (242 milyon parametr) başdan training etmək çox asanlıqla overfitting problemi yaradacaqdı, həm də lokalda training edildiyi üçün VRAM problemi ilə üzləşiləcəkdi. Buna görə də LoRA adapterindən ($r = 8, \alpha = 32$) istifadə edilərək, cəmi 884,736 parametr ilə training başa çatdırılmışdır.

GPU yaddaşına qənaət etmək üçün `fp16=True` (half-precision floating point format), `batch_size=2` və `gradient_accumulation=4` (effektiv olaraq batch size = 8) tətbiq edilmişdir.

2.1 Overfitting Problemi

Training prosesi 5 epoch-dan ibarətdir. Qrafikdən və loglardan göründüyü kimi, model 3-cü epoch-da optimal nöqtəyə (WER: 0.789, CER: 0.385) çatmışdır. 4-cü və 5-ci epoch-larda training loss 0.33-ə qədər düşsə də, validation WER göstəricisi 1.15-ə qədər kəskin artmışdır. Bu, modelin

overfitting etməyə başladığını göstərir (kiçik training loss, lakin böyük validation error). Kodda `load_best_model_at_end=True` istifadə edilərək, prosesin sonunda yalnız optimal model, yəni 3-cü epoch-un nəticəsi saxlanılmışdır.

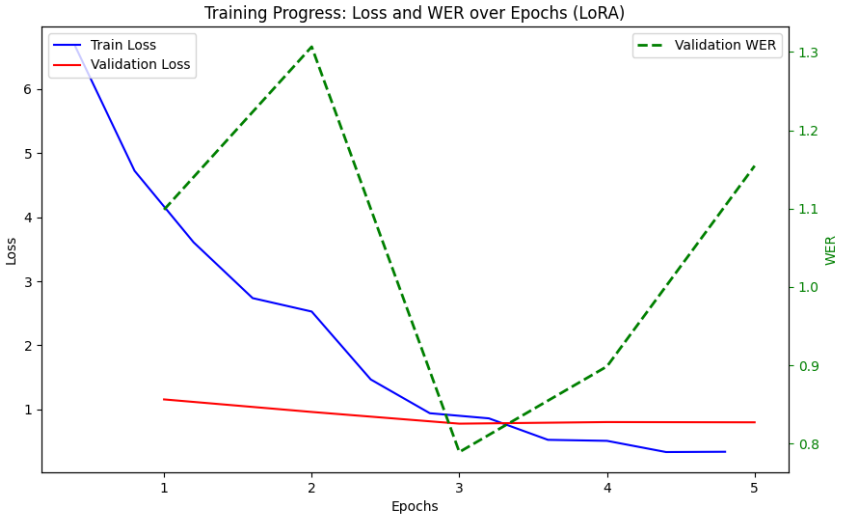


Figure 1: Training Progress: Loss and WER over Epochs (LoRA)

2.2 Fine-Tuning Nəticələri (B3)

Fine-tune edilmiş model 100 test audio faylı üzərində sınaqdan keçirilmişdir.

Model Növü	**WER (%)**	**CER (%)**
Baza Modeli (Whisper-Small)	92.77%	42.51%
Fine-Tuned Modeli (LoRA)	56.74%	16.70%

Table 1: Baza və Fine-Tuned Modellərin Müqayisəsi

3 Hissə C: Analitik Hesabat

3.1 C1. Çətinliklər və Həllər

Ən böyük texniki problem Hugging Face kitabxanalarinin versiyaları arasındakı konfliktlər oldu. Məsələn, yeniləmələrə görə `evaluation_strategy` parametri `eval_strategy` ilə, `tokenizer` isə `processing_class` ilə əvəz edilibmiş. Bu kimi xətalar dokumentasiyaya istinad edilərək, müvafiq arqumentlərin adlarını dəyişdikdən sonra həll edildi. İkinci böyük problem modelin ingilis dilinə tərcümə etməyə meyilli olması və bəzən ərəb əlifbası ilə cavablar qaytarması idi. Bunun qarşısını almaq üçün inferens zamanı `forced_decoder_ids` parametrində 'language=az' və 'task=transcribe' olaraq əlavə edildi.

Azərbaycan dili aqqlütinativ dildir, buna görə də kökə əlavə olunan bir səs belə sözün bütün mənasını və qrammatikasını dəyişə bilər. ASR sistemi sözün 90%-ni düzgün eşitsə də, sondakı bir hərfi səhv yazdıqda bu, avtomatik olaraq söz xətası (Word Error) kimi hesablanır. Buna görə də CER kifayət qədər aşağı olsa da, WER yüksək olaraq qalır.

3.2 C2. Nəticələrin Təhlili

Test nəticəsində CER 16.70%-ə düşmüşdür. Cəmi 200 səs faylı ilə training edildiyini nəzərə alsaq, modelin səsləri hərflərə bu dəqiqliklə çevirə bilməsi yaxşı nəticədir. Buna baxmayaraq modelin WER göstəricisi (56.74%) kommersiya məhsulu üçün yüksəkdir.

Səhvlər əsasən fonetik xarakter daşıyır. Model eşitdiyi səsləri lüğətə əsasən deyil, sırf səslənməyə görə hərflərə çevirir. Məsələn, "Moskvanı" əvəzinə "musqvanı", "səbəbləri" əvəzinə "savıqları" (b və v samitlərin akustik bənzərliyi), "sindromu" əvəzinə "sinrami".

Model arxa fon səslərinin az olduğu, aydın tələffüzü olan səslərdə daha yaxşı işləyir. Lakin "Common Voice" datasetinin audio fayllarinda arxa-fon səsi (background noise), sözlərin fərqli insanlar tərəfindən müxtəlif aksentlərlə və tələffüzlərlə səsləndirilməsi training və nəticə olaraq predicition proseslərini çətinləşdirir. Ancaq bu o demək deyildir ki, model ancaq ideal audio fayllar ilə training edilməlidir. Real həyat situasiyalarında həmişə bu kimi faktorlar vardır, buna görə production-level model training olunarkən belə audio faylların istifadəsi vacibdir.

3.3 C3. Yaxşılaşdırma Yolları

Model yalnız akustik (səs $\rightarrow$ hərf) olaraq training edilib. Production üçün mütləq şəkildə arxitekturaya **N-Gram** və ya statistik **Dil Modeli (Language Model)** əlavə edilməlidir. Dil modeli fonetik olaraq yanlış olan sözləri Azərbaycan dili lüğəti ilə müqayisə edib, ehtimalı daha yüksək olan sözlərlə əvəz edəcək.

Əgər daha çox resurs olsa idi, **data augmentation** - səslərin sürətini, tonunu dəyişərək və süni səslər əlavə edərək və ya əlavə data toplayaraq mövcud kiçik datanı artırmaq, **full fine-tuning** - yüksək həcmli GPU resurslarında LoRA adapteri olmadan modelin bütün parametrlərini minlərlə saatlıq data ilə training etmək, **LM inteqrasiyası** - transkripsiya mərhələsinin sonuna Azərbaycan dilində böyük mətnlərlə (məsələn, Wikipedia) training edilmiş statistik dil modeli əlavə etmək.

Azərbaycan dili üçün avtomatik nitq tanınmasının ən böyük problemi dilin şəkilçilərlə zəngin aqqlütinativ quruluşu səbəbindən mürəkkəb morfologiyasının olması və yüksək keyfiyyətli və böyük həcmli audio data-nın çatışmazlığıdır. Bundan əlavə, dil modeli inteqrasıyasına gəlincə, azərbaycan dilində cümlədəki söz sırasının daha sərbəst olması (məsələn, ingilis dili ilə müqayisədə) dil modelinin növbəti gələcək sözü ehtimallarla təxmin etməsini (n-gram prediction) çətinləşdirir.